

Nuevo Modelo de XAI basado en Análisis Formal de Conceptos

Andrés Rubio Ramos

Doble Grado en Ingeniería Informática y Matemáticas
Universidad de Sevilla

Dirigido por D. Joaquín Borrego Díaz

12 de junio de 2025

Estructura de la presentación

- Introducción, motivación y objetivos.
- Fundamentos del Análisis Formal de Conceptos (AFC).
- Razonamiento simbólico e implicaciones.
- AFC en Machine Learning.
- Caso Titanic.
- Ajustes y optimizaciones.
- Segundo caso: Churn.
- Explicabilidad del modelo
- Conclusiones y trabajo futuro.

Introducción, motivación y objetivos

- La **explicabilidad** en IA (XAI) es **clave** para aplicaciones reales.
- Necesitamos modelos comprensibles, auditables y fiables.
- Usar **AFC** para obtener **conocimiento interpretable**.
- **Validar** la utilidad explicativa del modelo en **datasets reales**.
- **Comparar** resultados usando **distintas bases** implicacionales.
- La fundamentación matemática del AFC está completamente **desarrollada** en la memoria escrita.

Definición: Contexto formal

Es una terna (O, A, I) donde:

- O es un conjunto de objetos,
- A es un conjunto de atributos,
- $I \subseteq O \times A$ es una relación binaria.

Definición: Operación de derivación

Sea $X \subseteq O$, su derivado (**intención**) es:

$$X' = \{y \in A \mid \forall x \in X, xIy\}$$

Análogamente, para $Y \subseteq A$, su derivado (**extensión**):

$$Y' = \{x \in O \mid \forall y \in Y, xIy\}$$

Definición: Implicación entre atributos

- Una **implicación** en AFC tiene la forma:

$$Y_1 \rightarrow Y_2, \quad \text{con } Y_1, Y_2 \subseteq A$$

Significa que todo objeto que tiene los atributos de Y_1 también tiene los de Y_2 .

- Un conjunto $T \subseteq A$ **respeta** la implicación si:

$$Y_1 \not\subseteq T \vee Y_2 \subseteq T$$

- Una implicación $Y_1 \rightarrow Y_2$ es **válida** en (O, A, I) si:

$$\forall o \in O, o' \text{ respeta } Y_1 \rightarrow Y_2$$

Definición: Consecuencia lógica

Dado un conjunto de implicaciones $\mathcal{L}$, decimos que una implicación $Y \rightarrow Z$ es una **consecuencia lógica** de $\mathcal{L}$ si, para todo conjunto $T \subseteq A$, cuando T respeta todas las implicaciones de $\mathcal{L}$, entonces también respeta $Y \rightarrow Z$. Se denota como:

$$\mathcal{L} \models Y \rightarrow Z$$

Definición: Base de implicaciones

Un conjunto $\mathcal{L}$ es una **base de implicaciones** de (O, A, I) si:

- Es **completa**: toda implicación válida es consecuencia lógica de $\mathcal{L}$.
- Es **irredundante**: ninguna implicación de $\mathcal{L}$ puede deducirse del resto.

Cierre implicacional y deducción

Definición: Cierre implicacional

Sea $L = \{Y_i \rightarrow Z_i\}_{i=1}^n$ un conjunto de implicaciones y $P \subseteq A$.
El **cierre implicacional** de P respecto de L es:

$$L(P) = \min\{Q \supseteq P \mid \forall i, Y_i \subseteq Q \Rightarrow Z_i \subseteq Q\}$$

Teorema: Deducción por cierre

Una implicación $I \rightarrow J$ se deduce de una base L si y solo si:

$$J \subseteq L(I)$$

Pseudo-intenciones y base de Stem

Definición: Pseudo-intención

Un conjunto $P \subseteq A$ es una **pseudo-intención** si:

- $P \neq P''$
- Para todo $Q \subsetneq P$, pseudo-intención, se cumple: $Q'' \subseteq P$

Teorema: Base de Stem

El conjunto de implicaciones:

$$\mathcal{L} = \{P \rightarrow P'' \mid P \text{ es pseudo-intención}\}$$

es una base de implicaciones **válidas** del contexto.

Definición: Confianza

La **confianza** de una implicación $Y_1 \rightarrow Y_2$ es:

$$\text{conf}(L) = \frac{|(Y_1 \cup Y_2)'|}{|Y_1'|}$$

Definición: Soporte

La **soporte** de una implicación $Y_1 \rightarrow Y_2$ es:

$$\text{supp}(L) = \frac{|(Y_1 \cup Y_2)'|}{|O|}$$

Definición: Base de Luxenburger

Dado un contexto M y umbrales de confianza γ y soporte δ , la base de Luxenburger es:


$$\mathcal{L}(M, \gamma, \delta) = \left\{ Y_1 \rightarrow Y_2 \mid \begin{array}{l} Y_1 \prec Y_2, \text{ cerrados} \\ \text{conf}(Y_1 \rightarrow Y_2) \geq \gamma, \text{supp}(Y_1 \rightarrow Y_2) \geq \delta \end{array} \right\}$$

Teorema: Completitud de Luxenburger

A partir de la base de Luxenburger se puede derivar cualquier otra implicación **no válida** del contexto junto con su respectivo soporte y confianza.

Además, es **minimal** entre los conjuntos que cumplen esta propiedad.

Esbozo de la demostración del teorema anterior



Base completa de reglas de asociación

- **Reglas de asociación estrictas:** las contenidas en la base Stem.
- **Reglas de asociación aproximadas:** las contenidas en la base Luxenburger.

Definición: Base completa de reglas de asociación

Fijados los umbrales de confianza γ y de soporte δ , la base completa de reglas de asociación de un contexto M está formada por la **base Stem** junto con la **base de Luxenburger** correspondiente.


¿Cómo entra el AFC en Machine Learning?

- El AFC genera **implicaciones simbólicas** a partir de un conjunto de datos.
- Estas implicaciones representan **conocimiento** estructurado, comprensible y útil.

Ejemplo

Clase = 1^a, Mujer → Superviviente

Tareas de clasificación



Limitaciones y desafíos

Transformación de datos a binario

- El AFC requiere datos binarios: presencia/ausencia de atributos.
- Se deben convertir todos los atributos a formato binario:
 - ▶ **Discretos:** codificación one-hot (una columna por categoría).
 - ▶ **Continuos o con muchos valores:** agrupar en rangos o aplicar umbrales.

Color	Rojo	Verde	Azul
Rojo	1	0	0
Azul	0	0	1
Verde	0	1	0

Limitaciones y desafíos

Impacto del escalado y transformación

- La forma de transformar los datos afecta:
 - ▶ A la calidad de las implicaciones.
 - ▶ A la eficiencia computacional.
- Una mala discretización genera implicaciones poco útiles o redundantes.

Nº de implicaciones totales:

Attr	Impl
25	638
30	922
35	1134
40	1338


Tiempo de ejecución (s):

Attr	Tiempo
25	92.3
30	109.3
35	115.9
40	121.6


Limitaciones y desafíos

Impacto del número de objetos

- A medida que aumentan los objetos en el conjunto de entrenamiento:
 - ▶ El número de implicaciones muestra saturación.
 - ▶ Aumenta el tiempo de ejecución (de forma no lineal).



Nº de implicaciones




Tiempo de ejecución

Limitaciones y desafíos

Interpretabilidad vs Precisión

- El AFC ofrece alta **interpretabilidad**: reglas claras y comprensibles.
- Pero puede limitar la **precisión** al no capturar relaciones complejas.
- Frente a modelos como redes neuronales, puede no aprovechar toda la riqueza de los datos.



Extraído de [2]

Conjunto de datos: Titanic (Kaggle [1])

Contexto general

Basado en el naufragio del **RMS Titanic** (1912). Contiene datos sobre 891 pasajeros: edad, clase, sexo, tarifa, y si sobrevivieron (Survived).

Archivos disponibles

- `train.csv`: 891 filas + Survived
- `test.csv`: 418 filas, sin Survived

Atributos

- `Pclass` (1–3): clase social
- `Id`, `Name`, `Sex`, `Age`
- `SibSp`, `Parch`: acompañantes
- `Ticket`, `Fare`, `Cabin`, `Embarked`
- `Survived`: variable objetivo (0/1)

Ejemplos del conjunto de datos

ID	Surv	Class	Name	Sex	Age
1	0	3	Braund, Mr. Owen Harris	male	22.0
2	1	1	Cumings, Mrs. John Bradley (Florence Briggs Th...)	female	38.0

Tabla: Datos personales de los primeros dos pasajeros del dataset.

SibSp	Parch	Ticket	Fare	Cabin	Emb
1	0	A/5 21171	7.25	—	S
1	0	PC 17599	71.2833	C85	C

Tabla: Información del viaje para los primeros dos pasajeros del dataset.

Preparación del modelo

- **Objetivo:** Construir las bases de implicaciones del contexto formal, núcleo del modelo AFC.
- **Estrategia:** Nueva subclase de `Context` en python que define los métodos de creación de bases, entre otros, del modelo a usar.
- Aplicamos rangos discretos a atributos **numéricos**:
 - ▶ **Age:** 6 intervalos desde 0 a 80 años.
 - ▶ **Fare:** 6 intervalos hasta el máximo (512).
 - ▶ **SibSp** y **Parch:** agrupan valores según frecuencia.
- Se codifican atributos **categoricos** (`Embarked`, `Pclass`, `Sex`).
- Total de **30 atributos** binarios tras transformación.
- División: **80 % entrenamiento (712), 20 % prueba (179).**

Análisis de resultados (base Luxenburger)

- A medida que aumentamos la confianza y el soporte, las reglas son menos numerosas pero más precisas.
- Máxima precisión con:
 - ▶ **Conf. = 0.800, Sup. = 0.045: 0.827** de acierto, solo 6 FP.
- Con confianza baja hay más reglas, pero solo aciertan un 38.5 %.
- Al subir el soporte, hay menos ruido, pero también menos reglas.

Resultados (base completa)

Conf.	Sup.	R. acierto	FP	FN	LHS	RHS	Total
0.000	0.000	0.385	110	0	6840	1898	19100
0.500	0.180	0.458	95	2	282	204	1242
0.800	0.180	0.637	55	10	276	203	1071
0.900	0.045	0.665	43	17	305	213	1154
0.950	0.045	0.698	32	22	283	207	1013
0.950	0.180	0.698	32	22	276	203	962

FP: falsos positivos.

FN: falsos negativos.

LHS: número de implicaciones con `Survived` en el **antecedente**.

RHS: número de implicaciones con `Survived` en el **consecuente**.

Análisis de resultados (base completa)

- Similar comportamiento al caso anterior, pero con reglas más generales (más atributos implicados).
- Mejores resultados:
 - ▶ **Conf. = 0.950, Sup. = 0.180**: acierto **0.698** con 962 reglas.
- Menor número de falsos positivos respecto a la base Luxenburger con mismos parámetros.
- A mayor confianza y soporte: baja cobertura, pero buena precisión.

Mejoras en la extracción de conocimiento

- **Eliminación de implicaciones con atributo *Survived* en antecedente:** Reduce la base sin afectar resultados.
- **Filtrado por soporte mínimo en base Stem:** Minimiza falsos positivos al conservar solo implicaciones frecuentes.
- **Reducción del cierre implicacional:** Solo se usan reglas con consecuente *Survived* y se limita a una ronda de disparo de reglas, mejorando precisión.

Resultados tras las mejoras (base completa)

Confianza	Soporte	Acierto	FP	FN	Total
0.500	0.000	0.581	71	4	1189
0.500	0.045	0.598	68	4	72
0.800	0.011	0.832	13	17	193
0.800	0.045	0.827	4	27	14
0.900	0.045	0.810	3	31	11
0.950	0.011	0.799	2	34	44

FP: falsos positivos.

FN: falsos negativos.





Ajuste de hiperparámetros: confianza, soporte y discretización

En esta sección se ajustan los hiperparámetros del modelo más allá de la confianza y soporte, incluyendo la discretización de atributos continuos por medio de rangos equidistantes (edad y tarifa).

Resultados:

- Mejor ratio de acierto: **0.844** (bases Luxenburger y completa).
- Se alcanza con los siguientes **parámetros**: confianza 80 %, soporte 16/712, rangos_age=4, rangos_fare=8.
- Los hiperparámetros más **determinantes** son **confianza y soporte**.
- Variar los **rangos** tiene un efecto **mínimo** en el desempeño.

Ratios de acierto según hiperparámetros



Resultados de Churn Modelling

- Dataset de **10,000** clientes bancarios con 14 atributos.
- **Objetivo:** predecir si un cliente **abandona el banco** (churn).
- Tiempo computacional elevado en **python** (tarda 1-2 días).
- Uso de **ConExp** para el cálculo de bases de implicaciones.
- Resultados:
 - ▶ **Base Stem:** mejor ratio de acierto 0.823.
 - ▶ **Base Luxenburger:** similar a Stem.
 - ▶ **Base Completa:** mejores resultados con 0.830.

Comparativa: Titanic vs Churn Modelling

- El **tiempo de ejecución crece** considerablemente con el número de objetos, llegando a ser necesario usar ConExp para Churn Modelling.
- Los **ratios de acierto** son **similares**: 0.844 para Titanic y 0.830 para Churn Modelling, pese a ser conjuntos de datos muy diferentes.
- A **mayor número de objetos**, la elección de **hiperparámetros** (confianza y soporte) tiene **menos impacto** en el ratio de acierto ya que los resultados de Churn son similares, aunque falsos positivos y negativos varíen.

XAI y AFC: Selección de Implicaciones

- AFC extrae **implicaciones**, de las cuales **varias** pueden ser disparadas para predecir un **único** objeto.
- Para **explicar** una predicción, se selecciona la **implicación** con **mayor confianza** que justifique dicha predicción.
- Ejemplo: para un pasajero del Titanic, elegir la regla con mayor confianza que explique su supervivencia o no supervivencia.

Verdaderos Positivos (VP)

- Pasajeros correctamente clasificados como supervivientes.
- Ejemplos de implicaciones disparadas:
 - ▶ {AgeGroup_20-40, SibSpGroup_1-3, Pclass_1}
→ Survived (confianza = 0.81)
 - ▶ {AgeGroup_20-40, Pclass_2, Female, ParchGroup_0-1, FareGroup_0-64}
→ Survived (confianza = 0.96)
- Interpretación: **Mujeres jóvenes en 1ª clase con familiares** tienen alta probabilidad de supervivencia.

Falsos Positivos (FP)

- Pasajeros predichos como supervivientes pero que no sobrevivieron.
- Ejemplos de implicaciones disparadas:
 - ▶ {AgeGroup_20-40, Pclass_2, Female, ParchGroup_0-1, FareGroup_0-64}
→ Survived (confianza = 0.96)
 - ▶ {ParchGroup_0-1, SibSpGroup_1-3, Pclass_1, Embarked_C}
→ Survived (confianza = 0.89)
- Estas reglas muestran dónde el modelo **sobreestima** la **supervivencia**.

Verdaderos Negativos (VN)

- Pasajeros correctamente clasificados como no supervivientes.
- Ejemplos de implicaciones disparadas:
 - ▶ {Pclass_3, SibSpGroup_3-5, ParchGroup_1-3, FareGroup_0-64}
 - NotSurvived (confianza = 0.86)
 - ▶ {Pclass_3, Embarked_S, AgeGroup_20-40, Male}
 - NotSurvived (confianza = 0.89)
- Interpretación: **Hombres en 3º clase** tienen baja probabilidad de supervivencia

Falsos Negativos (FN)

- Pasajeros predichos como no supervivientes pero que sobrevivieron.
- Ejemplos de implicaciones disparadas:
 - ▶ {Pclass_3, Embarked_S, AgeGroup_20-40, Male}
→ NotSurvived (confianza = 0.89)
 - ▶ {Male, Embarked_S, AgeGroup_20-40}
→ NotSurvived (confianza = 0.85)
- Estas reglas muestran dónde el modelo **sobreestima** la **no supervivencia**.

Conclusiones

- Se **diseñó** y **ajustó** un **modelo explicativo** basado en **AFC** para **mejorar** la **interpretabilidad** de modelos de aprendizaje automático.
- La **calidad** del conocimiento depende de la discretización, confianza, soporte, cantidad de datos y manejo de valores faltantes.
- El modelo puede llegar a ser una **herramienta útil** y prometedora para aumentar la explicabilidad en sistemas de IA, aunque requiere mejoras para optimizar su precisión.

Trabajo Futuro

- **Valores ausentes:** evaluar AFC sin rellenar datos faltantes, permitiendo implicaciones sin atributo objetivo en RHS.
- **Nuevos rangos de discretización:** usar rangos más expresivos (e.g. “menor que”, ordinales) para mejorar precisión.
- **Robustez ante perturbaciones:** analizar sensibilidad del modelo a cambios menores y buscar estabilización.
- **Uso del atributo objetivo negado:** estudiar implicaciones y modificar el modelo para añadir el atributo objetivo negado, para aumentar cobertura explicativa y posible mejora de los resultados.

Referencias I



Will Cukierski.

Titanic: Machine learning from disaster.

<https://www.kaggle.com/competitions/titanic,2012>.

Último acceso: 27 de mayo de 2025.



A. Diwali, K. Saeedi, K. Dashtipour, M. Gogate, E. Cambria, and A. Hussain.

Sentiment analysis meets explainable artificial intelligence: A survey on explainable sentiment analysis.

IEEE Transactions on Affective Computing, 15(3):837–846, 2024.

Nuevo Modelo de XAI basado en Análisis Formal de Conceptos

Andrés Rubio Ramos

Doble Grado en Ingeniería Informática y Matemáticas
Universidad de Sevilla

Dirigido por D. Joaquín Borrego Díaz

12 de junio de 2025